

Audio Sémantique Souverain :

Indexation et Veille Critique des Messages Vocaux

en langue Nationale : Le cas du Mooré

Domaine	Traitement du Langage Naturel · Intelligence Artificielle à faibles ressources
Durée	48 heures

1. Contexte et constat de départ

Au Burkina Faso, la voix est le premier medium de communication. WhatsApp, les groupes Facebook audio, les émissions des radios communautaires et les messages vocaux institutionnels constituent aujourd'hui le canal principal par lequel les citoyens, les agents de santé, les agriculteurs et les autorités locales échangent de l'information et ce, majoritairement en mooré, dioula ou fulfuldé.

Ce patrimoine vocal quotidien représente une masse de données d'une valeur considérable : signalements sanitaires, alertes communautaires, savoirs agricoles, témoignages et rumeurs circulant en temps réel. Or il est aujourd'hui totalement opaque aux systèmes numériques. Un agent de santé ne peut pas retrouver un message vocal d'il y a trois semaines signalant des cas de paludisme dans son district. Un responsable local ne peut pas savoir si un contenu audio circulant dans son village contient une rumeur dangereuse ou une alerte légitime. Un archiviste ne peut pas interroger 500 fichiers audio sans les écouter un à un.

Cette opacité repose sur trois défaillances structurelles indissociables :

- **Fracture linguistique numérique.** Les outils de traitement automatique de la parole (ASR) et de recherche sémantique disponibles sont massivement conçus pour l'anglais, le français ou l'arabe. Le mooré, le dioula et le fulfuldé sont des langues à ressources quasi nulles (extremely low-resource languages) : aucun modèle ASR robuste n'existe à ce jour pour ces langues, aucun moteur de recherche sémantique ne les prend en charge.
- **Dépendance à la transcription préalable.** Les architectures classiques de recherche dans l'audio supposent une transcription textuelle fiable comme étape intermédiaire. Sur des langues à faibles ressources, les taux d'erreur de transcription (WER) dépassent souvent 60 %, rendant toute indexation textuelle dérivée inexploitable. Il est impératif d'explorer des approches qui opèrent directement dans l'espace acoustique.
- **Absence de couche de criticité.** Même lorsqu'un message est retrouvé, aucun système ne qualifie automatiquement son niveau d'urgence : s'agit-il d'une conversation ordinaire, d'un signalement sanitaire, d'une rumeur déstabilisatrice, d'une alerte agricole ? Cette absence empêche tout mécanisme de veille proactive.

2. Formulation scientifique du problème

Le défi central peut être formulé en ces termes :

Étant donné une collection de messages audio en langues nationales burkinabè, peut-on concevoir un système capable (1) de répondre à une requête sémantique en localisant les segments audio les plus pertinents sans transcription intégrale préalable, et (2) d'attribuer à chaque segment un score de criticité qualifiant la nature et l'urgence de son contenu le tout sans dépendre d'un modèle externe propriétaire ?

Ce problème se décompose en trois sous-défis de recherche complémentaires :

SD1 - Représentation acoustique sémantique à faibles ressources

Comment construire des représentations vectorielles de segments audio capturant la sémantique du contenu, pour des langues quasi absentes des corpus d'entraînement supervisé mondiaux ? L'enjeu est d'exploiter des modèles de fondation multilingues (Whisper, MMS Meta, wav2vec2-XLSR, etc.) comme extracteurs de représentations transférables, sans fine-tuning massif. La capacité de ces modèles à généraliser sur le mooré et le dioula sans adaptation supervisée constitue une question ouverte à haute valeur scientifique.

SD2 - Alignement cross-modal requête / audio

La requête utilisateur sera formulée en texte (français ou transcription approximative en langue nationale) ou en voix. Le système doit aligner l'espace de représentation de la requête avec l'espace des segments audio dans une métrique de similarité cohérente. Cela implique de construire un espace sémantique partagé multimodal, s'appuyant sur des modèles d'embeddings multilingues (LaBSE, paraphrase-multilingual-MiniLM, mBERT) côté texte et sur des représentations acoustiques côté audio.

SD3 - Scoring de criticité multidimensionnel

Chaque segment retrouvé doit recevoir un score de criticité qualifiant sa nature selon plusieurs dimensions : urgence sanitaire (signalement de maladie, décès, rupture de médicaments), tension sociale (appels à la mobilisation, accusations, rumeurs), détresse individuelle (demande d'aide, signalement de danger), désinformation potentielle (contradiction avec des faits vérifiables), ou alerte agricole (invasion acridienne, sécheresse). Ce scoring peut reposer sur une classification supervisée légère (SVM, régression logistique) entraînée sur des exemples annotés manuellement pendant le hackathon, ou sur une approche zéro-shot via embeddings.

SD4 - Frugalité computationnelle

L'ensemble du pipeline segmentation, extraction de représentations, indexation vectorielle (FAISS, ChromaDB), inférence et interface doit fonctionner sur CPU standard ou GPU de faible capacité. Cette contrainte n'est pas accessoire : elle conditionne la déployabilité réelle de la solution dans l'infrastructure burkinabè et sahélienne.

3. Périmètre et livrables attendus en 48h

Compte tenu des contraintes temporelles et de la disponibilité des données, les équipes travailleront sur un corpus audio constitué pendant le hackathon lui-même. Chaque participant pourrait contribuer à produire des enregistrements de 2 à 5 minutes en mooré et/ou dioula sur des thématiques prédéfinies (santé, agriculture, sécurité, gouvernance locale), permettant de constituer un corpus contrôlé de 30 à 60 minutes au total dans les deux premières heures de l'événement. Un jeu de données déjà produit par le centre CITADEL sera disponibilisé. Des extraits d'émissions radio RTB disponibles en accès libre pourront compléter ce corpus.

Le prototype fonctionnel à livrer à l'issue des 48h devra démontrer les capacités suivantes :

- Ingestion et segmentation automatique du corpus audio en unités interrogeables (segments de 10 à 30 secondes avec horodatage).
- Extraction de représentations vectorielles par segment via un modèle de fondation multilingue.
- Réponse à une requête textuelle ou vocale en retournant les 5 segments les plus pertinents avec score de similarité et lien de lecture.
- Attribution d'un score de criticité à chaque segment selon au moins deux dimensions (ex. urgence sanitaire + tension sociale).
- Interface minimale permettant à un utilisateur non technique d'interagir avec le système (web, mobile ou ligne de commande documentée).
- Un + : Un agent qui peut intégrer un groupe whatsapp et permettre la recherche de contenu.

Les équipes sont libres du choix de l'architecture technique sous réserve du respect de la contrainte de souveraineté : aucune donnée audio ne doit transiter vers des APIs externes propriétaires. Tous les modèles utilisés doivent être exécutés localement (open weights).

4. Critères d'évaluation

Critère	Description	Poids
Pertinence des résultats	Évaluation humaine par jury bilingue : les segments retournés répondent-ils réellement à la requête ? (nDCG@5 ou évaluation qualitative)	25 %
Qualité du scoring de criticité	Cohérence et utilité du score attribué, validée par annotation de référence constituée en début de hackathon	20 %
Frugalité computationnelle	Temps d'inférence, ressources requises, capacité à tourner sans GPU dédié ou avec GPU bas de gamme	15 %
Robustesse acoustique	Comportement du système face à la variabilité : locuteurs multiples, bruit ambiant, dialectes, qualité d'enregistrement variable	15 %
Souveraineté technique	Absence totale de dépendance à des APIs externes ; modèles open weights exclusivement ; hébergeable localement	15 %
Présentation et impact	Clarté de la démo, qualité du pitch, vision de déploiement réel dans le contexte burkinabè	10 %

6. Stack technique suggérée (non contraignante)

Composante	Options recommandées	Justification
ASR / Embeddings audio	Whisper (small/medium), wav2vec2-large-XLSR-53, MMS Meta	Multilingues, open weights, fonctionnels sur langues africaines
Embeddings texte	LaBSE, paraphrase-multilingual-MiniLM-L12, mBERT	Multilingues, légers, CPU-friendly
Index vectoriel	FAISS (CPU), ChromaDB, Qdrant local	Open source, frugal, déployable hors cloud
Scoring de criticité	SVM / Logistic Regression (sklearn), zéro-shot via embeddings + seuils	Entraînable sur 50 à 100 exemples annotés en live
Interface	Streamlit, Gradio, FastAPI + HTML minimal	Déployable en 2h, aucun compte cloud requis
Langue de requête	Français + translittération mooré/dioula + requête vocale optionnelle	Accessibilité maximale pour l'utilisateur final

6. Ancrage stratégique national

Ce défi n'est pas un exercice académique isolé. Il s'inscrit directement dans la Feuille de Route Nationale d'Intelligence Artificielle du Burkina Faso 2026-2030, portée par le Ministère de la Transition Digitale, des Postes et des Communications Électroniques (MTDPCE).

Le Burkina Faso dispose d'une fenêtre stratégique : le marché de l'IA en langues africaines est quasi vierge. Aucune solution commerciale mature n'existe en mooré, dioula ou fulfuldé. Les équipes participantes travaillent sur un problème ouvert à impact institutionnel immédiat, dans un espace de recherche où une contribution de 48h peut générer une publication académique et alimenter une infrastructure nationale souveraine.

7. Cadre éthique et de souveraineté (VERTUS)

Toutes les solutions développées dans le cadre de ce défi doivent respecter le cadre VERTUS (Équité, Éthique, Redevabilité, Transparence, Utilité, Souveraineté) de la FdR IA BF. En particulier :

- Consentement explicite : le corpus audio utilisé est constitué exclusivement avec l'accord informé des locuteurs, ou à partir de contenus diffusés dans des espaces publics ouverts (émissions radio, groupes communautaires publics, messages institutionnels). Aucune collecte de messages privés sans consentement.
- Souveraineté des données : aucun fichier audio du corpus hackathon ne transite vers des plateformes ou APIs externes. Tous les modèles sont exécutés localement.
- Transparence algorithmique : le score de criticité doit être explicable à l'utilisateur final. Toute classification doit pouvoir être contestée et corrigée.
- Non-discrimination : les équipes veilleront à ce que le système ne produise pas de biais systématiques selon le genre du locuteur, la région ou le dialecte.